

POLITECHNIKA ŁÓDZKA

WYDZIAŁ FIZYKI TECHNICZNEJ, INFORMATYKI
I MATEMATYKI STOSOWANEJ

Kierunek: Matematyka Stosowana
Specjalność: Matematyka finansowa i ubezpieczeniowa

O ROZKŁADZIE SUMY ZMIENNYCH LOSOWYCH

Maciej Domagała
Numer albumu: 219998

Praca magisterska
napisana pod kierunkiem dr inż. Violetty Lipińskiej
Instytut Matematyki

ŁÓDŹ, MAJ 2019

Spis treści

Wstep

Rozdział 1

Podstawowe definicje i oznaczenia

1.1 Podstawowe definicje

Poniższa praca dotyczy pewnych własności zmiennych losowych, a zatem wskazane jest przytoczenie pewnych podstawowych definicji z zakresu probabilistyki.

Definicja 1 ([3], str. 18)

Trójkę (Ω, \mathcal{F}, P) gdzie P jest funkcją prawdopodobieństwa określoną na σ -ciele \mathcal{F} podzbiórów zbioru zdarzeń elementarnych Ω , nazywamy przestrzenią probabilistyczną.

Definicja 2 ([3], str. 75)

Funkcję $X : \Omega \rightarrow \mathbb{R}$ nazywamy zmienną losową o wartościach w \mathbb{R} , jeżeli dla każdego $a \in \mathbb{R}$ zbiór $X^{-1}((-\infty, a])$ jest zdarzeniem, czyli $X^{-1}((-\infty, a]) \in \mathcal{F}$.

Głównymi zmiennymi losowymi rozważanymi w tej pracy będą ciągłe zmienne losowe zdefiniowane następująco:

Definicja 3 ([1], str. 31)

Mówimy, że zmienna losowa X jest typu ciągłego, jeżeli istnieje nieujemna funkcja f , określona i całkowalna do jedynki na całej osi, spełniająca warunek

$$\forall_{[x_1, x_2]} P(\{\omega : x_1 \leq X(\omega) \leq x_2\}) = \int_{x_1}^{x_2} f(x) dx.$$

Definicja 4 ([1], str. 35)

Niech $p \in (0, 1)$. Liczbę $q_p(X)$ spełniającą warunki:

$$P(X \leq q_p(X)) \geq p \wedge P(X < q_p(X)) \leq p$$

nazywamy kwantylem rzędu p zmiennej losowej X .

Kwantyle tego samego rzędu tworzą przedział $[q_X^-(p), q_X^+(p)]$ gdzie

$$\begin{aligned} q_X^-(p) &= \sup\{x : P(X < x) < p\} \\ &= \inf\{x : F(x) \geq p\} \end{aligned}$$

oraz

$$\begin{aligned} q_X^+(p) &= \inf\{x : F(x) > p\} \\ &= \sup\{x : P(X < x) \leq p\}. \end{aligned}$$

Można zauważyć, że gdy zmienna losowa X ma ciągłą i ściśle rosnącą dystrybucję, to zachodzi równość $q_X^-(p) = q_X^+(p)$ dla każdego $p \in (0, 1)$.

1.2 Miara ryzyka

Główną miarą ryzyka rozpatrywaną w tej pracy jest miara Value at Risk, zaproponowana w latach pięćdziesiątych zeszłego wieku przez m. in. Henry'ego Markowitza. W latach osiemdziesiątych firma JP Morgan wprowadziła system kalkulacji metryk VaR dla firm jako zastępstwo dla dotychczasowego systemu obliczania ryzyk portfeli inwestycyjnych. Sama miara jak i jej liczne pochodne (Expected Shortfall, CVaR) jest używana do dziś np. w przepisach regulacji zasad wypłacalności firm "Wypłacalność II" opublikowanych przez Europejski Urząd Nadzoru Ubezpieczeń i Pracowniczych Programów Emerytalnych (EIOPA).

Definicja 5 Niech X będzie zmienną losową o dystrybucji F , oznaczającą wielkość straty portfela inwestycyjnego. Na zadanym poziomie ufności $p \in (0, 1)$, Value at Risk jest najmniejszą taką liczbą x , że prawdopodobieństwo przekroczenia jej przez X jest nie większe niż $(1 - p)$:

$$VaR_p(X) = \inf\{x \in \mathbb{R} : F(x) \geq p\} = q_p(X).$$

Niech \mathcal{L} oznacza przestrzeń zmiennych losowych opisanych na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) , reprezentujących stratę portfela inwestycyjnego w pewnym usta-

lonym przedziale czasu. W celu poprawnego zdefiniowania miary ryzyka zakładać będziemy, że dla dowolnych $X_1, X_2 \in \mathcal{L}$ oraz $\lambda > 0$ zachodzi $X_1 + X_2 \in \mathcal{L}$ oraz $\lambda X_1 \in \mathcal{L}$.

Definicja 6 ([4], str. 5)

Funkcję rzeczywistą $\rho : \mathcal{L} \rightarrow \mathbb{R}$ nazywamy miarą ryzyka.

W pracy Artznera z 1999 roku przedstawione zostało pojęcie miar koherentnych, czyli spełniających pewne aksjomaty przedstawione poniżej. Koherentność miary ryzyka jest z finansowego punktu widzenia pożądanym zjawiskiem, wskazującym na dobre przełożenie pomiędzy zachowaniem ryzyk finansowych a wartością miary ryzyka.

Definicja 7 ([4], str. 7)

Miarę ryzyka $\rho : \mathcal{L} \rightarrow \mathbb{R}$ nazywamy koherentną, jeżeli spełnia własności:

1. *monotoniczności, czyli dla dowolnych $X, Y \in \mathcal{L}$*

$$X \leq Y \Rightarrow \rho(X) \leq \rho(Y),$$

2. *niezmienności na przesunięcia, czyli dla dowolnego $c \in \mathbb{R}$ i $X \in \mathcal{L}$*

$$\rho(X + c) = \rho(X) + c,$$

3. *dodatniej jednorodności, czyli dla dowolnego $\lambda > 0$ i $X \in \mathcal{L}$*

$$\rho(\lambda X) = \lambda \rho(X),$$

4. *podaddytywności, czyli dla dowolnych $X, Y \in \mathcal{L}$*

$$\rho(X + Y) \leq \rho(X) + \rho(Y).$$

Warto zauważyć, że pomimo dużej popularności miary Value at Risk, nie spełnia ona wszystkich warunków powyższej definicji.

Lemat 1

Miara ryzyka Value at Risk spełnia warunki dodatniej jednorodności, niezmienniczości na przesunięcia oraz monotoniczności, natomiast nie spełnia warunku podaddytywności. Nie jest zatem koherentną miarą ryzyka.

Dowód.

Niech $p \in \mathbb{R}$.

1. Pokażmy warunek monotoniczności. Niech $X, Y \in \mathcal{L}$, $x \in \mathbb{R}$ oraz $X \leq Y$.

Zauważmy, że $Y \leq x \Rightarrow X \leq x$, co bezpośrednio implikuje $\{\omega \in \Omega : Y(\omega) \leq x\} \subset \{\omega \in \Omega : X(\omega) \leq x\}$. Zatem dla dowolnego poziomu ufności $p \in \mathbb{R}$ zachodzi

$$P(Y \leq x) \geq p \Rightarrow P(X \leq x) \geq p.$$

Z dowolności $x \in \mathbb{R}$ mamy zatem

$$\{x \in \mathbb{R} : P(Y \leq x) \geq p\} \subset \{x \in \mathbb{R} : P(X \leq x) \geq p\},$$

co z własności infimum zbiorów daje

$$\inf\{x \in \mathbb{R} : P(X \leq x) \geq p\} \leq \inf\{x \in \mathbb{R} : P(Y \leq x) \geq p\}.$$

Zatem $VaR_p(X) \leq VaR_p(Y)$.

2. Pokażmy warunek niezmienniczości na przesunięcia. Niech $c \in \mathbb{R}$ i $X \in \mathcal{L}$.

$$VaR_p(X+c) = \inf\{x \in \mathbb{R} : P(X+c \leq x) \geq p\} = \inf\{x \in \mathbb{R} : P(X \leq x-c) \geq p\}.$$

Dla $y = x - c$ mamy $x = y + c$ i z własności infimum zbioru

$$\begin{aligned} \inf\{x \in \mathbb{R} : P(X \leq x-c) \geq p\} &= \inf\{y+c \in \mathbb{R} : P(X \leq y) \geq p\} = \\ &= \inf\{y \in \mathbb{R} : P(X \leq y) \geq p\} + c = VaR_p(X) + c. \end{aligned}$$

3. Pokażmy warunek dodatniej jednorodności. Niech $\lambda > 0$ i $X \in \mathcal{L}$.

$$\begin{aligned} VaR_p(\lambda X) &= \inf\{x \in \mathbb{R} : P(\lambda X \leq x) \geq p\} = \inf\left\{x \in \mathbb{R} : P\left(X \leq \frac{x}{\lambda}\right) \geq p\right\} \\ &= \inf\{\lambda x \in \mathbb{R} : P(X \leq x) \geq p\} = \lambda VaR_p(X). \end{aligned}$$

4. Pokażmy kontrprzykład na warunek podaddytywności. Niech $p = 0.95$.

Niech X będzie zmienną losową o rozkładzie dyskretnym, który można opisać poniższą tabelą

X	100	0
p_i	0.96	0.04

Niech Y będzie zmienną losową o tym samym rozkładzie, niezależną od X .

Zauważmy, że $VaR_{0.95}(X) = VaR_{0.95}(Y) = 0$.

Rozważmy rozkład sumy $X + Y$. Możemy go przedstawić następująco

$X + Y$	200	100	0
p_i	$(0.96)^2 = 0.9216$	0.0768	$(0.04)^2 = 0.0016$

Otrzymujemy, że $VaR_{0.95}(X + Y) = 100$, zatem $VaR_{0.95}(X + Y) = 100 \not\leq 0 + 0 = VaR_{0.95}(X) + VaR_{0.95}(Y)$, co przeczy warunkowi subaddytywności.

□

1.2.1 Definicja z punktu widzenia inwestora

Należy nadmienić, że w literaturze występuje zróżnicowanie dotyczące sposobu definiowania Value at Risk oraz aksjomatów określających koherentną miarę ryzyka. Podane w tym podrozdziale definicje dotyczą mierzenia zmiennych losowych opisujących pewną **stratę**. Takie podejście zaprezentowane jest np. w [5], [6] i dotyczy tzw. "ubezpieczeniowej" wersji Value at Risk. Często (np. w [2]) Value at Risk definiowany jest dla zmiennych losowych określających **zysk** inwestora, wówczas wprowadzany jest wzór

$$VaR_p^z(X) = -q_X^+(p) = -\inf\{x : P(X \leq x) > p\} = VaR_p(-X).$$

Jeżeli zmienna losowa X przyjmuje jedynie wartości dodatnie, czyli inwestor na pewno nie poniesie żadnych strat, $VaR_p^z(X)$ przyjmuje wartości ujemne, zatem kapitał inwestora nie jest zagrożony. Znajdywanie wartości VaR portfela związane jest z oszacowaniem dystrybuanty, stąd też w tej pracy wykorzystywana jest definicja VaR bezpośrednio nawiązująca do rozkładu, czyli "kwantylowa" definicja VaR .

Rozdział 2

Ograniczenia dystrybuanty rozkładu sumy zmiennych losowych

Rozważmy łączny portfel ubezpieczyciela $\sum_{i=1}^n X_i$ składający się z ryzyk opisanych przez wektor $X = (X_1, \dots, X_n)$, gdzie dystrybuanty brzegowe $F_i \sim X_i$ są znane, ale struktura zależności pomiędzy składowymi portfela jest nieznana. Problem polega na znalezieniu największej i najmniejszej wartości Value at Risk. Zważywszy na przyjętą definicję VaR (kwantyl rozkładu), problem w dużej mierze polega na rozpatrzeniu różnych postaci rozkładu sumy zmiennych losowych. Co za tym idzie, w tym i kolejnym rozdziale przedstawione zostaną rozważania dotyczące ograniczeń dystrybuanty sumy zmiennych oraz twierdzenie łączące otrzymane wyniki z ograniczeniami VaR .

Wprowadźmy oznaczenia:

$$M_n(t) := \sup \left\{ P \left(\sum_{i=1}^n X_i \leq t \right) : X_i \sim F_i, 1 \leq i \leq n \right\}$$

oraz

$$m_n(t) := \inf \left\{ P \left(\sum_{i=1}^n X_i \leq t \right) : X_i \sim F_i, 1 \leq i \leq n \right\},$$

gdzie supremum i infimum są brane z uwzględnieniem wszystkich możliwych zależności między zmiennymi X_i . Wówczas powyższe wzory indukują naturalną zależność

$$m_n(t) \leq P \left(\sum_{i=1}^n X_i \leq t \right) \leq M_n(t).$$

Na początku przedstawione zostanie twierdzenie wprowadzające tzw. standardowe ograniczenia dystrybuanty sumy zmiennych losowych. Przedstawmy najpierw dwie wykorzystywane w twierdzeniu definicje.

Definicja 8 ([5], str. 72)

Niech $t \in \mathbb{R}$. Liczbę

$$\bigwedge_{i=1}^n F_i(t) := \inf \left\{ \sum_{i=1}^n F_i(u_i) : \sum_{i=1}^n u_i = t \right\}$$

nazywamy **minimalnym splotem** dystrybuant (F_i) , zaś liczbę

$$\bigvee_{i=1}^n F_i(t) := \sup \left\{ \sum_{i=1}^n F_i(u_i) : \sum_{i=1}^n u_i = t \right\}$$

nazywamy **maksymalnym splotem** dystrybuant (F_i) .

Twierdzenie 2 ([5], str. 72)

Niech $X = (X_1, \dots, X_n)$ będzie wektorem losowym o dystrybuantach brzegowych F_1, \dots, F_n .

Wówczas dla dowolnego $t \in \mathbb{R}$ zachodzą nierówności:

$$\max \left(\bigvee_{i=1}^n F_i(t) - (n-1), 0 \right) \leq P \left(\sum_{i=1}^n X_i \leq t \right) \leq \min \left(\bigwedge_{i=1}^n F_i(t), 1 \right).$$

Dowód.

Niech $n \in \mathbb{N}$, $t \in \mathbb{R}$ oraz niech $u_1, \dots, u_n \in \mathbb{R}$ będą tak dobrane, że $\sum_{i=1}^n u_i = t$.

Pokażmy najpierw, że zachodzi nierówność

$$P \left(\sum_{i=1}^n X_i \leq t \right) \leq P \left(\bigcup_{i=1}^n \{X_i \leq u_i\} \right) \quad (\star)$$

Rozważmy następujące podzbiory przestrzeni \mathbb{R}^n :

$$\begin{aligned} A_1 &= \{x = (x_1, \dots, x_n) \in \mathbb{R}^n : x_1 + \dots + x_n > u_1 + \dots + u_n\} \\ A_2 &= \{x = (x_1, \dots, x_n) \in \mathbb{R}^n : \{x_1 > u_1\} \cap \dots \cap \{x_n > u_n\}\} \end{aligned}$$

Zauważmy, że dla pewnego małego $\epsilon > 0$ możemy dobrać następujące elementy:

$$x_1 = u_1 + \epsilon$$

$$x_1 = u_1 + \epsilon$$

$$\begin{aligned} & \vdots \\ x_{n-1} &= u_{n-1} + \epsilon \\ x_n &= u_n - \frac{(n-1)\epsilon}{2}. \end{aligned}$$

Wówczas

$$x_1 + \dots + x_n = u_1 + \dots + u_n + (n-1)\epsilon - \frac{(n-1)\epsilon}{2} = u_1 + \dots + u_n + \frac{(n-1)\epsilon}{2}.$$

Widać, że $x = (x_1, \dots, x_n) \in A_1$, ale $x_n < u_n$, zatem $x = (x_1, \dots, x_n) \notin A_2$.

Z drugiej strony, jeżeli dla pewnego $x = (x_1, \dots, x_n) \in \mathbb{R}^n$ zachodzi warunek $\forall_i x_i > u_i$, to naturalnie $x_1 + \dots + x_n > u_1 + \dots + u_n$. Z powyższych wnioskujemy, że $A_2 \subset A_1$ oraz $A_1 \not\subset A_2$. Przechodząc do prawdopodobieństwa, mamy zatem $P(A_2) < P(A_1)$, co implikuje $P(A_1^c) < P(A_2^c)$, gdzie A_i^c oznacza dopełnienie zbioru A_i .

Przyjmując $A_1 = \left\{ \sum_{i=1}^n X_i > t \right\}$ oraz $A_2 = \bigcup_{i=1}^n \{X_i > u_i\}$ dostajemy

$$P\left(\sum_{i=1}^n X_i \leq t\right) = P(A_1^c) < P(A_2^c) = P\left(\left(\bigcap_{i=1}^n \{X_i > u_i\}\right)^c\right) = P\left(\bigcup_{i=1}^n \{X_i \leq u_i\}\right).$$

Ponadto zauważmy, że

$$P\left(\bigcup_{i=1}^n \{X_i \leq u_i\}\right) \leq \sum_{i=1}^n P(\{X_i \leq u_i\}) = \sum_{i=1}^n F_i(u_i). \quad (\star \star)$$

Ograniczenie zostało pokazane dla dowolnych $u_1, \dots, u_n \in \mathbb{R}$ spełniających $\sum_{i=1}^n u_i = t$. Biorąc elementy $u_1, \dots, u_n \in \mathbb{R}$ minimalizujące sumę dystrybuant i korzystając z (\star) oraz $(\star \star)$ mamy więc

$$P\left(\sum_{i=1}^n X_i \leq t\right) \leq \min\left(\bigwedge_{i=1}^n F_i(t), 1\right).$$

Ograniczenie z góry zostało pokazane, pokażmy teraz ograniczenie z dołu.

Udowodnimy pomocniczą nierówność

$$\sum_{i=1}^n F_i(t) - (n-1) \leq P(X_1 \leq u_1, \dots, X_n \leq u_n). \quad (\star')$$

Pokażemy ją w sposób indukcyjny. Zauważmy wpierw, że dla $n = 2$ zbiorów A_1 i A_2 zachodzi $P(A \cap B) = P(A) + P(B) - P(A \cup B)$, zatem

$$P(A \cap B) \geq P(A) + P(B) - 1 = P(A) + P(B) - (n - 1)$$

Założmy, że dla dowolnego $n \in \mathbb{N}$ i zbiorów A_1, \dots, A_n zachodzi

$$P\left(\bigcap_{i=1}^n A_i\right) \geq \sum_{i=1}^n P(A_i) - (n - 1). \quad (i)$$

Wówczas dla $n + 1$ zbiorów A_1, \dots, A_{n+1} zachodzi

$$\begin{aligned} P\left(\bigcap_{i=1}^{n+1} A_i\right) &= P\left(\bigcap_{i=1}^n A_i \cap A_{n+1}\right) \geq P\left(\bigcap_{i=1}^n A_i\right) + P(A_{n+1}) - 1 \geq \\ &\sum_{i=1}^n P(A_i) - (n - 1) + P(A_{n+1}) - 1 = \sum_{i=1}^{n+1} P(A_i) - ((n + 1) - 1). \end{aligned}$$

Zatem indukcyjnie pokazaliśmy nierówność (i). Kładąc $A_i = \{X_i \leq u_i\}$ otrzymujemy wzór \star' . Ponadto, powtarzając rozumowanie z pierwszej części dowodu, jeżeli dla pewnego $x = (x_1, \dots, x_n) \in \mathbb{R}^n$ zachodzi warunek $\forall_i x_i \leq u_i$, to naturalnie $x_1 + \dots + x_n \leq u_1 + \dots + u_n$. Stąd wynika

$$P(X_1 \leq u_1, \dots, X_n \leq u_n) \leq P\left(\sum_{i=1}^n X_i \leq t\right) \quad (\star\star')$$

Korzystając z \star' oraz $\star\star'$ oraz dobierając u_i maksymalizujące sumę dystrybuant otrzymujemy ograniczenie z dołu. Łącząc ograniczenia z góry i z dołu otrzymujemy tezę twierdzenia.

□

Należy nadmienić, że udowodnione powyżej twierdzenie jest dość ogólne - zachodzi dla dowolnej liczby zmiennych losowych oraz dla dowolnych postaci dystrybuant tych zmiennych. Wiąże się z tym pewne ograniczenie dokładności wyprowadzonych nierówności, bowiem pokazane w twierdzeniu 2 ograniczenia można polepszyć już dla $n \geq 3$ zmiennych, zakładając znajomość rozkładów X_i . Mimo tego ogólność zastosowania twierdzenia jest użyteczna - otrzymane wyniki można wykorzystać np. przy numerycznym poszukiwaniu wartości dystrybuanty sumy wykorzystując metodę poławiania - wówczas przedział otrzymany przy użyciu twierdzenia 2 możemy traktować jako przedział startowy algorytmu.

Okazuje się, że dla $n = 2$ zmiennych losowych ograniczenia twierdzenia 2 są optymalne - równe są odpowiednio $m_2(t)$ oraz $M_2(t)$. W kolejnym rozdziale zostanie przedstawiony dowód tego faktu.

Rozdział 3

Maksymalny i minimalny VaR dla sumy dwóch zmiennych losowych

3.1 Ograniczenia dystrybuanty sumy dwóch zmiennych losowych

Niech zmienne losowe X_1 i X_2 mają dystrybuanty odpowiednio $F_1(x) = P(X_1 \leq x)$ i $F_2(x) = P(X_2 \leq x)$. Wprowadźmy ponadto dla uproszczenia zapisów $\psi_i(p) = \text{VaR}_p(X_i) = \inf\{x \in \mathbb{R} : F_i(x) \geq p\}$. Wobec oznaczeń wprowadzonych w poprzednim rozdziale można pokazać, że

$$M_2(t) = \inf_{0 < u_1 < t} \{F_1(u_1) + F_2(t - u_1)\}, \quad (3.1)$$

$$m_2(t) = \sup_{0 < u_1 < t} \{F_1(u_1) + F_2(t - u_1)\} - 1. \quad (3.2)$$

zakładając, że obie wartości należą do przedziału $[0, 1]$. W tej pracy zamieszczone zostaną dowody twierdzeń dotyczących $M_2(t)$ - idee wykorzystywane przy rozważaniu $m_2(t)$ są analogiczne.

Aby pokazać (3.1), zauważmy najpierw pewną relację.

Twierdzenie 3 (własne)

Niech

$$p^* = \inf_{0 < u_1 < t} \{F_1(u_1) + F_2(t - u_1)\} \quad (3.3)$$

oraz

$$\bar{c} = \sup \left\{ 0 < c < 1 : \sup_{0 < p < c} \{\psi_1(p) + \psi_2(c - p)\} < t \right\}. \quad (3.4)$$

Wówczas $p^* = \bar{c}$.

Dowód.

I. Pokażemy, że $p^* \leq \bar{c}$.

Założmy, że $p^* > \bar{c}$. Wówczas istnieje $\epsilon > 0$ takie, że $p^* > p_\epsilon^* = p^* - \epsilon > \bar{c}$. Warunek $p_\epsilon^* > \bar{c}$ oznacza istnienie takiego $p' \in (0, p_\epsilon^*)$, że $\psi_1(p') + \psi_2(p_\epsilon^* - p') \geq t$.

Przypuśćmy pierw, że $\psi_1(p') + \psi_2(p_\epsilon^* - p') = t$.

Przyjmując $u'_1 = \psi_1(p')$ oraz $u'_2 = \psi_2(p_\epsilon^* - p')$ uzyskujemy $u'_1 + u'_2 = t$ oraz $F_1(u'_1) + F_2(u'_2) = p' + p_\epsilon^* - p' = p_\epsilon^* < p^*$ co przeczy definicji p^* .

Przypuśćmy, że $\psi_1(p') + \psi_2(p_\epsilon^* - p') = t' > t$.

Ponownie, niech $u'_1 = \psi_1(p')$ i $u'_2 = \psi_2(p_\epsilon^* - p')$. Skoro $t' > t$ to $t' - u'_1 > t - u'_1$. Zatem z monotoniczności dystrybuanty

$$F_1(u'_1) + F_2(t - u'_1) \leq F_1(u'_1) + F_2(t' - u'_1) = p_\epsilon^*.$$

Z drugiej strony

$$p^* = \inf_{0 < u'_1 < t} \{F_1(u'_1) + F_2(t - u'_1)\} \leq F_1(u'_1) + F_2(t - u'_1),$$

Co prowadzi do $p^* \leq p_\epsilon^*$, zatem sprzeczność z $p^* > p_\epsilon^*$.

II. Pokażemy, że $p^* \geq \bar{c}$.

Założmy, że $p^* < \bar{c}$. Wówczas dla dowolnego $p' \in (0, p^*)$ zachodzi $\psi_1(p') + \psi_2(p^* - p') < t$.

Z drugiej strony $p^* = F_1(u_1^*) + F_2(t - u_1^*)$ dla pewnego $u_1^* \in (0, t)$, więc

$$\psi_1(p_1^*) + \psi_2(p^* - p_1^*) = t,$$

co ponownie doprowadza do sprzeczności.

□

Podobnie można przeprowadzić dowód twierdzenia

Twierdzenie 4 (własne)

Niech

$$p^{**} = \sup_{0 < u_1 < t} \{F_1(u_1) + F_2(t - u_1)\} - 1. \quad (3.5)$$

oraz

$$\underline{c} = \inf \left\{ 0 < c < 1 : \inf_{c < p < 1} \{\psi_1(p) + \psi_2(1 + c - p)\} \geq t \right\}. \quad (3.6)$$

Wówczas $p^{**} = \underline{c}$.

Wnioskując z twierdzenia (3), aby pokazać (3.1) wystarczy pokazać, że $M_2(t) = \bar{c}$. Twierdzenie w takiej formie zostało udowodnione przez Makarova w 1981 roku. Dowód z uwzględnieniem prawostronnie ciągłej dystrybuanty zostanie przedstawiony poniżej.

Twierdzenie 5 ([3], str. 804)

Niech t będzie dowolną liczbą rzeczywistą. Wówczas zachodzi równość:

$$M_2(t) = \sup \left\{ 0 < c < 1 : \sup_{0 < p < c} \{ \psi_1(p) + \psi_2(c - p) \} < t \right\}.$$

Twierdzenie 6 ([3], str. 804)

Niech t będzie dowolną liczbą rzeczywistą. Wówczas zachodzi równość:

$$m_2(t) = \inf \left\{ 0 < c < 1 : \inf_{c < p < 1} \{ \psi_1(p) + \psi_2(1 + c - p) \} \geq t \right\}.$$

Przedstawmy najpierw metodę zdefiniowania zmiennej losowej θ wykorzystywaną w dowodzie. Zauważmy, że dla dowolnej zmiennej losowej X o dystrybuancie F możemy skonstruować zmienną θ w następujący sposób: gdy dla zdarzenia losowego ω zachodzi $P(X = X(\omega)) = 0$, to $\theta(\omega) = F(X(\omega))$, zaś gdy $P(X = X(\omega)) = p_i > 0$, to zmienna losowa θ jest jednostajnie określona na przedziale $[F(X(\omega)) - p_i, F(X(\omega))]$. Tak określona zmienna θ ma rozkład jednostajny na przedziale $[0, 1]$.

Ponadto, zachodzi twierdzenie:

Twierdzenie 7 ([7], str. 111)

Niech θ będzie zmienną losową o rozkładzie jednostajnym na przedziale $[0, 1]$ niech zmienna losowa X będzie zdefiniowana jako $\psi(\theta)$, gdzie $\psi(p) = \inf\{x : F(x) \geq p\}$ dla pewnej dystrybuanty F . Wówczas zachodzą warunki:

1. $\{X \leq x\} = \{\theta \leq F(x)\}$ dla dowolnego $x \in \mathbb{R}$
2. $X = \psi(\theta)$ ma rozkład o dystrybuancie F .

Dowód.

Niech $x \in \mathbb{R}$ oraz $X \leq x$. Wówczas $\psi(\theta) \leq x$ czyli $\inf\{t : F(t) \geq \theta\} \leq x$. To z kolei oznacza, że dla dowolnego $\epsilon > 0$ zachodzi $F(x + \epsilon) \geq \theta$, co z prawostronnej ciągłości dystrybuanty daje bezpośrednio $F(x) \geq \theta$.

Niech teraz $\theta \leq F(x)$ dla pewnego $x \in \mathbb{R}$. Wówczas $X = \psi(\theta) = \inf\{t : F(t) \geq \theta\} \leq x$, co dowodzi punktu 1 twierdzenia. Punkt 2 jest bezpośrednim następstwem punktu 1.

□

Dowód twierdzenia 4.

Niech X_1 i X_2 będą zmiennymi losowymi o dystrybuantach odpowiednio F_1 i F_2 . Wprowadźmy oznaczenie

$$\bar{c} = \sup\{0 < c < 1 : \sup_{0 < p < c} \psi_1(p) + \psi_2(c-p)\} < t\}.,$$

I. Pokażemy, że $M_2(t) \geq \bar{c}$.

Dla zmiennej losowej X_1 skonstruujemy zmienną losową θ_1 w sposób podany wcześniej.

Niech $0 \leq c \leq \bar{c}$ oraz

$$\theta_2 = \begin{cases} c - \theta_1 & \text{dla } \theta_1 < c \\ \theta_1 & \text{dla } \theta_1 \geq c \end{cases}$$

Zauważmy, że $\psi_2(\theta_2)$ ma rozkład o dystrybuancie F_2 . Mamy

$$\begin{aligned} P(\psi_2(\theta_2) \leq y) &= P(\{\psi_2(c - \theta_1) \leq y\} \wedge \{\theta_1 < c\}) \\ &= P(\{\psi_2(\theta_1) \leq y\} \wedge \{\theta_1 \geq c\}) = P_1 + P_2. \end{aligned}$$

Zauważmy, że dla dowolnego $y \in \mathbb{R}$ zachodzi zależność

$$\{p : p < F(y)\} \subseteq \{p : \psi(p) \leq y\} \subseteq \{p : p \leq F(y)\}. \quad (\star_1)$$

Istotnie, niech $y \in \mathbb{R}$ oraz $p < F(y)$ i założmy, że $\psi(p) > y$. To oznaczałoby, że $\inf\{x : F(x) \geq p\} > y$, czyli, że dla dowolnego x spełniającego $F(x) \geq p$ zachodzi $x > y$.

Zauważmy jednak, że istnieje takie $\epsilon > 0$, że $p + \epsilon < F(y)$. Niech x_1 będzie takie, że $F(x_1) = p + \epsilon$. Wówczas z jednej strony $F(x_1) = p + \epsilon > p$, zaś z drugiej $F(x_1) = p + \epsilon < F(y)$ co pociąga za sobą $x_1 \leq y$. Otrzymujemy sprzeczność z założeniem $\psi(p) > y$.

Pokażmy teraz drugie zawieranie. Niech $\psi(p) \leq y$ i założmy, że $p > F(y)$. Warunek $\psi(p) \leq y$ oznacza, że istnieje takie x_1 , że $F(x_1) \geq p$ i $x_1 \leq y$. Skoro $x_1 \leq y$ to z własności dystrybuanty $F(x_1) \leq F(y)$ i finalnie $p \leq F(x_1) \leq F(y)$ co przeczy założeniu $p > F(y)$. Powyższe rozważania dowodzą (\star_1) .

Niech $F_2(y) \leq c$. Korzystając z wykazanej zależności (\star_1) możemy zaprezentować poniższe nierówności:

$$\begin{aligned} P_1 &= P(\{\psi_2(c - \theta_1) \leq y\} \wedge \{\theta_1 < c\}) \leq P(\{c - \theta_1 \leq F_2(y)\} \wedge \{\theta_1 < c\}) \\ &= P(c - F_2(y) \leq \theta_1 < c) = c - (c - F_2(y)) = F_2(y), \end{aligned}$$

$$\begin{aligned} P_1 &= P(\{\psi_2(c - \theta_1) \leq y\} \wedge \{\theta_1 < c\}) \geq P(\{c - \theta_1 < F_2(y)\} \wedge \{\theta_1 < c\}) \\ &= P(c - F_2(y) < \theta_1 < c) = c - (c - F_2(y)) = F_2(y), \end{aligned}$$

$$P_2 = P(\{\psi_2(\theta_1) \leq y\} \wedge \{\theta_1 \geq c\}) \leq P(\{\theta_1 \leq F_2(y)\} \wedge \{\theta_1 \geq c\}) = 0,$$

skąd otrzymujemy $P_1 + P_2 = F_2(y)$.

Niech $F_2(y) > c$. Wówczas w podobny sposób korzystając z zależności (\star_1) otrzymujemy:

$$\begin{aligned} P_1 &= P(\{\psi_2(c - \theta_1) \leq y\} \wedge \{\theta_1 < c\}) \leq P(\{c - \theta_1 \leq F_2(y)\} \wedge \{\theta_1 < c\}) \\ &= P(c - F_2(y) \leq \theta_1 < c) = P(\theta_1 < c) = c, \end{aligned}$$

$$\begin{aligned} P_1 &= P(\{\psi_2(c - \theta_1) \leq y\} \wedge \{\theta_1 < c\}) \geq P(\{c - \theta_1 < F_2(y)\} \wedge \{\theta_1 < c\}) \\ &= P(c - F_2(y) < \theta_1 < c) = P(\theta_1 < c) = c, \end{aligned}$$

$$\begin{aligned} P_2 &= P(\{\psi_2(\theta_1) \leq y\} \wedge \{\theta_1 \geq c\}) \geq P(\{\theta_1 < F_2(y)\} \wedge \{\theta_1 \geq c\}) \\ &= P(c \leq \theta_1 \leq F_2(y)) = F_2(y) - c, \end{aligned}$$

$$\begin{aligned} P_2 &= P(\{\psi_2(\theta_1) \leq y\} \wedge \{\theta_1 \geq c\}) \leq P(\{\theta_1 \leq F_2(y)\} \wedge \{\theta_1 \geq c\}) \\ &= P(c \leq \theta_1 \leq F_2(y)) = F_2(y) - c, \end{aligned}$$

skąd ponownie otrzymujemy $P_1 + P_2 = F_2(y)$. Finalnie oznacza to, że $P(\psi_2(\theta_2) \leq y) = F_2(y)$ dla dowolnego $y \in \mathbb{R}$, zatem $\psi_2(\theta_2) \sim F_2$. Z twierdzenia 5 wiemy również, że $\psi_1(\theta_1) \sim F_1$.

Niech zatem $c < \bar{c}$. Mamy

$$\begin{aligned} P(X_1 + X_2 \leq t) &= P(\psi_1(\theta_1) + \psi_2(\theta_2) \leq t) \\ &= P(\{\psi_1(\theta_1) + \psi_2(\theta_2) \leq t\} \wedge \{\theta_1 < c\}) \\ &\quad + P(\{\psi_1(\theta_1) + \psi_2(\theta_2) \leq t\} \wedge \{\theta_1 \geq c\}) = c + \tilde{P}_2 \geq c, \end{aligned}$$

co wobec dowolności $c < \bar{c}$ daje

$$M_2(t) \geq \bar{c}. \tag{3.7}$$

II. Pokażemy, że $M_2(t) \leq \bar{c}$.

Niech $n \in \mathbb{N}$ będzie dostatecznie dużą liczbą naturalną. Wprowadźmy oznaczenia:

$$x_i = \psi_1\left(\frac{i}{n}\right); \quad y_i = \psi_2\left(\frac{i}{n}\right), \quad i = 0, 1, \dots, n$$

Ponadto, niech

$$k_0 = \max\{1 \leq k \leq n : \max(x_i + y_{k-i+1}) \leq t\}$$

Pokażemy dwie nierówności:

$$M_2(t) \leq \frac{k_0 + 2}{n} \text{ oraz } \frac{k_0}{n} \leq \bar{c} + \frac{3}{n}$$

IIa. $M_2(t) \leq \frac{k_0 + 2}{n}.$

Nierówność jest oczywista dla $k_0 \geq n - 2$. Niech więc $k_0 \leq n - 3$ oraz wprowadźmy zbiory:

$$A_k = \left\{ \frac{k-1}{n} \leq \theta_1 < \frac{k}{n} \right\} \text{ i } B_k = \left\{ \frac{k-1}{n} \leq \theta_2 < \frac{k}{n} \right\}, \quad k = 1, \dots, n.$$

Z definicji k_0 wynika, że istnieje taki indeks i_0 , $1 \leq i_0 \leq k_0$, że $x_{i_0} + y_{k_0-i_0+2} > t$. Rozważmy $r \geq i_0 + 1$ oraz $s \geq k_0 - i_0 + 3$. Wówczas widać, że na zbiorze A_r zachodzi $\theta_1 \geq \frac{i_0}{n}$, czyli $\psi_1(\theta_1) \geq x_{i_0}$, natomiast na zbiorze B_s zachodzi $\theta_2 \geq \frac{k_0 - i_0 + 2}{n}$, co implikuje $\psi_2(\theta_2) \geq y_{k_0-i_0+2}$. Stąd i z możemy wnioskować, że na $A_r \cap B_s$ zachodzi $X_1 + X_2 = \psi_1(\theta_1) + \psi_2(\theta_2) \geq x_{i_0} + y_{k_0-i_0+2} > t$. Wówczas korzystając z dopełnień zbiorów

$$\begin{aligned} \{X_1 + X_2 \leq t\} &\subseteq (A_r \cap B_s)' = A_r' \cup B_s' = \bigcup_{i=1}^{i_0} A_i \cup \bigcup_{i=1}^{k_0-i_0+2} B_i = \\ &= \left\{ \theta_1 < \frac{i_0}{n} \right\} \cup \left\{ \theta_2 < \frac{k_0 - i_0 + 2}{n} \right\} = C. \end{aligned}$$

Korzystając z własności prawdopodobieństwa otrzymujemy wniosek

$$P(X_1 + X_2 \leq t) \leq P(C) = \frac{i_0}{n} + \frac{k_0 - i_0 + 2}{n} = \frac{k_0 + 2}{n}.$$

Bezpośrednio stąd otrzymujemy $M_2(t) \leq \frac{k_0 + 2}{n}$.

IIb. $\frac{k_0}{n} \leq \bar{c} + \frac{3}{n}.$

Niech $j_0 \in \mathbb{N}$ będzie takie, że $\frac{j_0 - 1}{n} \leq \bar{c} < \frac{j_0}{n}$. Pokażemy wówczas, że $\frac{k_0}{n} \leq \frac{j_0 - 1}{n} + \frac{3}{n}$ czyli

$$k_0 \leq j_0 + 2. \quad (\star)$$

Zauważmy, że dla $j_0 \geq n-2$ nierówność w **IIb** jest oczywista. Niech więc $1 \leq j_0 \leq n-3$. Istnieje taka $\delta > 0$, że $c_2 = \bar{c} + \delta < \frac{j_0}{n}$. Rozważmy dowolny indeks $0 \leq i < j_0$ oraz $p \in \left[\frac{i}{n}; \frac{i+1}{n}\right]$. Mamy $c_2 - p \leq \frac{j_0}{n} - \frac{i+1}{n} = \frac{j_0 - i - 1}{n}$, zatem z monotoniczności funkcji ψ

$$\psi_1(p) + \psi_2(c_2 - p) \leq \psi_1\left(\frac{i+1}{n}\right) + \psi_2\left(\frac{j_0 - i - 1}{n}\right)$$

Z dowolności i mamy wówczas

$$\sup_{0 < p < c_2} \{(\psi_1(p) + \psi_2(c_2 - p))\} \leq \max_{1 \leq i \leq j_0} (x_i + y_{j_0-i+2}). \quad (\star_1)$$

Jednocześnie z definicji \bar{c}

$$\sup_{0 < p < c_2} \{(\psi_1(p) + \psi_2(c_2 - p))\} > t \quad (\star_2)$$

oraz z definicji k_0

$$\max_{1 \leq i \leq k_0} (x_i + y_{k_0-i+1}) \leq t. \quad (\star_3)$$

Łącząc nierówności \star_1 , \star_2 i \star_3 dostajemy

$$\max_{1 \leq i \leq k_0} (x_i + y_{k_0-i+1}) < \max_{1 \leq i \leq j_0} (x_i + y_{j_0-i+2}) = x_{l_0} + y_{j_0-l_0+2}. \quad (\star_4)$$

dla pewnego $1 \leq l_0 \leq j_0$.

Jeśli $k_0 \leq j_0$ to $k_0 \leq j_0 + 2$ co dowodzi \star .

Jeśli $k_0 \geq j_0 + 1$ to zauważmy, że z \star_4

$$x_{l_0} + y_{k_0-l_0+1} < x_{l_0} + y_{j_0-l_0+2} \Rightarrow k_0 < j_0 + 1$$

co przeczy założeniu, że $k_0 \geq j_0 + 1$. Zatem zachodzi \star i bezpośrednio stąd mamy prawdziwość **IIb**.

Z **IIa** oraz **IIb** dostajemy

$$M_2(t) \leq \frac{k_0}{n} + \frac{2}{n} \leq \bar{c} + \frac{3}{n} + \frac{2}{n} = \bar{c} + \frac{5}{n} \quad (3.8)$$

co z dowolności $n \in \mathbb{N}$ daje ostatecznie **II**. Z **I** i **II** otrzymujemy tezę twierdzenia. \square

3.2 Postać maksymalnego i minimalnego VaR

Z twierdzenia udowodnionego w poprzednim rozdziale możemy wywnioskować postać VaR dla sumy dwóch zmiennych losowych. Wprowadźmy analogiczne oznaczenia

do tych z rozdziału 2. Niech $p \in (0, 1)$ i $S_n = X_1 + \dots + X_n$. Oznaczmy

$$\overline{VaR}_p(S_n) := \sup \{VaR_p(S_n) : X_i \sim F_i, 1 \leq i \leq n\}, \quad (3.9)$$

$$\underline{VaR}_p(S_n) := \inf \{VaR_p(S_n) : X_i \sim F_i, 1 \leq i \leq n\}, \quad (3.10)$$

Wówczas prawdziwy jest poniższy wniosek

Wniosek z twierdzeń 5 i 6 ([8], str. 14)

Dla dowolnego $p \in (0, 1)$ zachodzą zależności

$$\overline{VaR}_p(X_1 + X_2) = \inf_{x \in [0, 1-p]} \{F_1^{-1}(p+x) + F_2^{-1}(1-x)\} \quad (3.11)$$

oraz

$$\underline{VaR}_p(X_1 + X_2) = \sup_{x \in [0, p]} \{F_1^{-1}(x) + F_2^{-1}(p-x)\}. \quad (3.12)$$

Obserwacją z powyższego wniosku jest fakt, że gdy współczynnik korelacji pomiędzy zmiennymi X_1 i X_2 wynosi $\rho = 1$ (pełna komonotoniczność pomiędzy zmiennymi), to VaR niekoniecznie jest maksymalizowany. Prezentacją tej zależności może być przykład dotyczący dwóch zmiennych o rozkładzie normalnym. Zauważmy wpierw, że zachodzi twierdzenie

Twierdzenie 8 ([9], str. 52)

Niech X będzie zmienną losową o rozkładzie normalnym ze średnią μ oraz wariancją σ^2 o gęstości

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right].$$

Wówczas dla dowolnego $p \in (0, 1)$ zachodzi

$$VaR_p(X) = \mu + \sigma \Phi^{-1}(p).$$

Dowód.

Korzystając bezpośrednio z definicji VaR oraz standaryzacji zmiennej losowej otrzy-

ujemy ciąg zależności

$$\begin{aligned}
VaR_p(X) &= \inf \{x \in \mathbb{R} : P(X \leq x) \geq p\} \\
&= \inf \left\{ x \in \mathbb{R} : P \left(\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma} \right) \geq p \right\} \\
&= \inf \left\{ x \in \mathbb{R} : \Phi \left(\frac{x - \mu}{\sigma} \right) \geq p \right\} \\
&= \inf \left\{ x \in \mathbb{R} : \frac{x - \mu}{\sigma} \geq \Phi^{-1}(p) \right\} \\
&= \inf \{x \in \mathbb{R} : x \geq \mu + \sigma \Phi^{-1}(p)\} = \mu + \sigma \Phi^{-1}(p)
\end{aligned}$$

Przykład 1.

Niech zmienne losowe X_1, X_2 mają rozkład normalny z wartością oczekiwaną 0 oraz wariancją równą 1. Oznaczmy dystrybuanty tych zmiennych losowych jako F_1, F_2 . Niech $p = 0,95$.

Bazując na wzorze (2.2), wprowadźmy funkcję g określoną wzorem:

$$g(x) = F_1^{-1}(0,95 + x) + F_2^{-1}(1 - x).$$

Interesuje nas minimum tej funkcji w przypadku, gdy $x \in [0; 0,05]$.

Widzimy, że minimum tej funkcji jest osiągane dla $x = 0,025$ i wynosi:

$$g(0,025) = F_1^{-1}(0,975) + F_2^{-1}(0,975) = 2 \cdot F_1^{-1}(0,975) = 2 \cdot 1,959964 = 3,919928.$$

Zatem $\overline{VaR}_{0,95}(X_1 + X_2) = 3,919928$.

Z drugiej strony, suma $X_1 + X_2$ ma rozkład $N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\rho\sigma_1\sigma_2)$ dla $X_1 \sim N(\mu_1, \sigma_1^2)$ i $X_2 \sim N(\mu_2, \sigma_2^2)$ oraz korelacji ρ pomiędzy nimi. Wobec tego dla $X_1, X_2 \sim N(0, 1)$ i $\rho = 1$ z poprzedniego twierdzenia dostajemy

$$VaR_{0,95}(X_1 + X_2) = \sqrt{4} \cdot \Phi^{-1}(0,95) = 2 \cdot 1,6449 = 3,2898.$$

Co za tym idzie, pełna komonotoniczność liniowa nie jest przypadkiem, w którym otrzymujemy maksymalny VaR sumy.

Bibliografia

- [1] Gajek L, Kałuszka M.: *Wnioskowanie statystyczne*, WNT, Warszawa 1996.
- [2] Jakubowski J.: *Modelowanie rynków finansowych*, Script, Warszawa 2006.
- [3] Jakubowski J., Sztencel R.: *Rachunek prawdopodobieństwa dla (prawie) każdego*, Script, Warszawa 2002.
- [4] Artzner P., Eber J., Delbaen F., Heath D.: *Coherent Measures of Risk*, Mathematical Finance 9(3):203-228, 1999.
- [5] Makarov G.D: *Estimates for the distribution function of a sum of two random variables when the marginal distribution are fixed*, Theory of Probability & Its Applications: Vol. 26, No. 4,1982.
- [5] Ruschendorf L., *Mathematical Risk Analysis*, Springer, Berlin 2013.
- [6] McNeil J. A., Frey R., Embrechts P., *Quantitative Risk Management: Concepts, Techniques and Tools*, Princeton University Press, 2005.
- [7] Shorack R. Galen, *Probability for Statisticians*, Springer-Verlag New York, 2000.
- [8] Embrechts P, *Risk Aggregation under Dependence Uncertainty - Challenges in Theory and Practice*, Selected talk presentation, 2014.
- [9] Panjer H.H., *Operational Risk: Modeling Analytics*, John Wiley and Sons, 2006.